

# Optimisation sous contraintes

Joon Kwon

Master 2 — MathSV

7 octobre 2021

Dans ce chapitre,

- $f: \mathbb{R}^d \rightarrow \mathbb{R}$
- $C \subset \mathbb{R}^d$  ensemble de points admissibles

on considère le problème :

$$\min_{x \in C} f(x),$$

qu'on écrit aussi :

$$\begin{array}{ll} \text{minimiser} & f(x) \\ \text{soumis à} & x \in C \end{array}$$

Methode du gradient projeté

Méthodes de pénalisation

Conditions KKT

Dualité lagrangienne

# Methode du gradient projeté

# Définition

On suppose que  $C$  est **convexe** et **fermé**.

## Proposition

Soit  $y \in \mathbb{R}^d$ .  $x \mapsto \|y - x\|^2$  admet un **unique minimiseur** sur  $C$ .

## Définition

Cet unique minimiseur est appelé **projection orthogonale** de  $y$  sur  $C$  et est noté  $\text{proj}_C(y)$ .

## Définition (Gradient projeté)

Soit  $x^{(1)} \in \mathbb{R}^d$  et  $(\gamma^{(t)})_{t \geq 1}$  une suite strictement positive. On appelle **descente de gradient projeté** associée à la fonction objectif  $f$ , à l'ensemble convexe fermé  $C$ , au point initial  $x^{(1)}$  et aux pas  $(\gamma^{(t)})_{t \geq 1}$  la suite  $(x^{(t)})_{t \geq 1}$  définie par :

$$x^{(t+1)} = \text{proj}_C \left\{ x^{(t)} - \gamma^{(t)} \nabla f(x^{(t)}) \right\}, \quad t \geq 1.$$

Pertinent quand la projection sur  $C$  est moins difficile à résoudre que le problème initial.

# Garanties pour $f$ convexe

## Théorème

On suppose que  $f$  admet un minimiseur  $x^*$  sur  $C$ .

- Si  $f$  est convexe et  $L$ -régulière, le choix  $\gamma^{(t)} = 1/L$  garantit

$$f(x^{(T+1)}) - f(x^*) \leq \frac{L \|x^{(1)} - x^*\|^2}{2T}.$$

- Si  $f$  est  $L$ -régulière et  $K$ -fortement convexe, le choix  $\gamma^{(t)} = 1/L$  garantit

$$f(x^{(T+1)}) - f(x^*) \leq \frac{L}{2} \|x^{(1)} - x^*\|^2 \cdot \left(1 - \frac{K}{L}\right)^T.$$

Mêmes garanties que pour la descente de gradient pour la minimisation sans contraintes.

# Garanties pour $f$ non-convexe

On définit une application de «gradient alternatif» associée à  $f$  et  $C$  par :

$$G_\gamma(x) = \frac{x - \text{Proj}_C(x - \gamma \nabla f(x))}{\gamma}, \quad x \in \mathbb{R}^d, \gamma > 0.$$

Ce qui assure  $x^{(t+1)} = x^{(t)} - \gamma^{(t)} G_{\gamma^{(t)}}(x^{(t)})$ .

## Théorème

*Si  $f$  est seulement  $L$ -régulière, le choix  $\gamma^{(t)} = 1/L$  garantit*

$$\min_{1 \leq t \leq T} \|G_{1/L}(x^{(t)})\|^2 \leq \frac{4L(f(x^{(1)}) - f(x^*))}{T}.$$

# Méthodes de pénalisation



# Pénalisation extérieure

- On remplace la contrainte par un terme supplémentaire dans la fonction à minimiser.
- On se donne  $\phi: \mathbb{R}^d \rightarrow \mathbb{R}$  une fonction telle que :

$$\phi(x) = 0 \text{ si } x \in C, \quad \text{et} \quad \phi(x) > 0 \text{ si } x \notin C.$$

- Soit  $\varepsilon > 0$  et on considère le problème approché :

$$\begin{aligned} &\text{minimiser} && f(x) + \frac{1}{\varepsilon}\phi(x) \\ &\text{soumis à} && x \in \mathbb{R}^d. \end{aligned}$$

- Plus  $\varepsilon$  est petit, plus le problème est proche du problème initial.
- La solution  $x_\varepsilon^*$  peut ne pas appartenir à  $C$ .

# Exemple de résolution par pénalisation

- **Principe** : on résout successivement des approximations de plus en plus proches du problème initial.
- On choisit  $\varepsilon^{(1)} > 0$ , et on résout approximativement :

$$\begin{aligned} &\text{minimiser} && f(x) + \frac{1}{\varepsilon^{(1)}} \phi(x) \\ &\text{soumis à} && x \in \mathbb{R}^d. \end{aligned}$$

par une méthode de notre choix.

- À l'étape  $t \geq 2$ ,
  - on choisit  $\varepsilon^{(t)}$  tel que  $0 < \varepsilon^{(t)} < \varepsilon^{(t-1)}$
  - on résout approximativement :

$$\begin{aligned} &\text{minimiser} && f(x) + \frac{1}{\varepsilon^{(t)}} \phi(x) \\ &\text{soumis à} && x \in \mathbb{R}^d. \end{aligned}$$

en prenant  $x^{(t-1)}$  pour point initial.

# Pénalisation intérieure

Si on souhaite des solutions approchées appartenant strictement à  $C$

- On se donne  $\phi: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$  telle que :

$$\forall x \notin C, \quad \phi(x) = +\infty.$$

- Soit  $\varepsilon > 0$  et on considère :

$$\begin{array}{ll} \text{minimiser} & f(x) + \varepsilon \phi(x) \\ \text{soumis à} & x \in \mathbb{R}^d \end{array}$$

- Exemple :  $C = \mathbb{R}_+^d$ .  $\phi(x) = -\sum_{i=1}^d \log x_i$ .

## Conditions KKT

# Problèmes de minimisation sous forme standard

$$\begin{array}{ll} \text{minimiser} & f(x) \\ \text{soumis à} & h_i(x) = 0 \quad (1 \leq i \leq p) \\ & g_j(x) \leq 0 \quad (1 \leq j \leq q) \end{array} \quad (\text{P})$$

où les  $g_j$  et  $h_i$  sont des applications  $\mathbb{R}^d \rightarrow \mathbb{R}$ .

Autrement dit, il s'agit du problème

$$\min_{x \in C} f(x) \quad \text{où} \quad C = \left\{ x \in \mathbb{R}^d, \quad \begin{array}{l} \forall i = 1, \dots, p, \quad h_i(x) \leq 0 \\ \forall j = 1, \dots, q, \quad g_j(x) = 0 \end{array} \right\}.$$

## Definition (Contraintes actives et inactives)

Soit  $x \in \mathbb{R}^d$ . Une contrainte d'inégalité " $g_j(x) \leq 0$ " est dite **active** (ou **saturée**) (resp. **inactive**) en  $x$  si :

$$g_j(x) = 0 \quad (\text{resp.} \quad g_j(x) < 0).$$

# Théorème de Fritz John

## Théorème (Fritz John)

Soit  $x^* \in C$  une solution de (P). Si les fonctions  $f, g_j, h_i$  sont  $\mathcal{C}^1$  en  $x^*$ , il existe  $\lambda_1, \dots, \lambda_p \in \mathbb{R}$  et  $\mu_0, \mu_1, \dots, \mu_q \in \mathbb{R}_+$  tels que :

$$\begin{cases} \mu_0 \nabla f(x^*) + \sum_{i=1}^p \lambda_i \nabla h_i(x^*) + \sum_{j=1}^q \mu_j \nabla g_j(x^*) = 0 \\ \forall j = 1, \dots, q, \quad \mu_j g_j(x^*) = 0. \end{cases}$$

- Si  $\mu_0 = 0$ , la propriété ci-dessus ne donne aucune information sur  $f$ , seulement sur  $C$ .
- Les coefficients  $(\lambda_i)_{1 \leq i \leq p}$  et  $(\mu_j)_{1 \leq j \leq q}$  sont appelés **multiplicateurs de Lagrange**

# Conditions KKT

## Definition

Un point  $x^* \in C$  vérifie les conditions KKT (Karush-Kuhn-Tucker) si les  $f, h_i, g_j$  sont  $C^1$  en  $x^*$  et s'il existe  $\lambda_1, \dots, \lambda_p \in \mathbb{R}$  et  $\mu_1, \dots, \mu_q \in \mathbb{R}_+$  tels que :

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^p \lambda_i \nabla h_i(x^*) + \sum_{j=1}^q \mu_j \nabla g_j(x^*) = 0 \\ \forall j = 1, \dots, q, \quad \mu_j g_j(x^*) = 0. \end{cases}$$

- On appelle **qualification des contraintes** une condition nécessaire pour qu'une solution de (P) satisfasse les conditions KKT. Il en existe un grand nombre.
- On dit que **les contraintes sont qualifiées** en un point  $x \in C$  si une telle condition nécessaire est satisfaite.

# Qualification des contraintes

## Proposition

Soit  $x^* \in C$  une solution de (P). On suppose que les  $f, g_j, h_i$  sont  $\mathcal{C}^1$  en  $x^*$ . Si de plus *une des conditions* suivantes est vérifiée, alors  $x^*$  satisfait les conditions KKT.

- (i) Les fonctions  $h_i$  et  $g_j$  sont affines
- (ii) la famille composée des vecteurs  $\nabla h_i(x^*)$  (pour  $i = 1, \dots, p$ ) et des vecteurs  $\nabla g_j(x^*)$  (pour  $j$  tel que  $g_j(x^*) = 0$ ) est linéairement indépendante.
- (iii) Les fonctions  $f, g_j$  sont convexes, les  $h_j$  affines, et il existe  $x \in C$  tel que  $g_j(x) < 0$  pour tout  $j = 1, \dots, q$ . (condition de Slater)

Il existe de nombreuses autres conditions de qualification.



# Dualité lagrangienne

# Lagrangien

## Definition

Le **lagrangien** de (P) est la fonction  $L: \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q \rightarrow \mathbb{R}$  définie par :

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^p \lambda_i h_i(x) + \sum_{j=1}^q \mu_j g_j(x).$$

- On voit que : 
$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu) = \begin{cases} f(x) & \text{si } x \in C \\ +\infty & \text{sinon.} \end{cases}$$
- Donc (P) se réécrit : 
$$\min_{x \in C} f(x) = \min_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu)$$

# Dualité faible

On définit le problème dual de (P) par

$$\begin{array}{ll} \text{maximiser} & \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) \\ \text{soumis à} & \lambda \in \mathbb{R}^p \\ & \mu \in \mathbb{R}_+^q. \end{array} \quad (\text{P}^*)$$

## Proposition

$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) \leq \inf_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu).$$

# Dualité forte

## Definition

$(x^*, \lambda^*, \mu^*) \in \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q$  est un **point-selle** du lagrangien si :

$$\forall (x, \lambda, \mu) \in \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q, \quad L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*).$$

## Proposition

*S'il existe un point-selle  $(x^*, \lambda^*, \mu^*)$  de  $L$ , alors,*

$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) = \inf_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu) = L(x^*, \lambda^*, \mu^*).$$

*Si de plus, les fonctions  $f, h_i, g_j$  sont  $\mathcal{C}^1$ ,  $x^*$  vérifie les **conditions KKT** avec  $(\lambda^*, \mu^*)$  pour multiplicateurs de Lagrange.*

Alors,

- On dit qu'il y a **dualité forte**.
- $x^*$  est solution du problème primal.
- $(\lambda^*, \mu^*)$  est solution du problème dual.

# Réciproque dans le cas convexe

## Proposition

On suppose que :

- les fonctions  $f, h_i, g_j$  sont  $\mathcal{C}^1$
- les fonctions  $f, g_j$  sont *convexes*
- les fonctions  $h_i$  *affines*.
- $x^* \in C$  une *solution* de  $(P)$  vérifiant les *conditions KKT* (on note  $(\lambda^*, \mu^*)$  les multiplicateurs de Lagrange).

Alors  $(x^*, \lambda^*, \mu^*)$  est un *point-selle* de  $L$ .

Et il y a donc dualité forte.

# Algorithme d'Uzawa

L'algorithme d'Uzawa, consiste à appliquer la **méthode du gradient projeté au problème dual** ( $P^*$ ).

- Initialisation :  $\lambda^{(1)} \in \mathbb{R}^p, \mu^{(1)} \in \mathbb{R}_+^q$  quelconques.
- Pour  $t \geq 1$ ,

$$x^{(t)} = \arg \min_{x \in \mathbb{R}^d} L(x, \lambda^{(t)}, \mu^{(t)})$$

$$\lambda^{(t+1)} = \lambda^{(t)} + \gamma^{(t)} h_i(x^{(t)}), \quad \forall i = 1, \dots, p,$$

$$\mu^{(t+1)} = \max \left( 0, \mu^{(t)} + \gamma^{(t)} g_j(x^{(t)}) \right), \quad \forall j = 1, \dots, q,$$