

Optimisation sous contraintes

Joon Kwon

Master 2 — MathSV

7 octobre 2021

Dans ce chapitre,

- $f: \mathbb{R}^d \rightarrow \mathbb{R}$
- $C \subset \mathbb{R}^d$ ensemble de points admissibles

on considère le problème :

$$\min_{x \in C} f(x),$$

qu'on écrit aussi :

$$\begin{array}{ll} \text{minimiser} & f(x) \\ \text{soumis à} & x \in C \end{array}$$

Methode du gradient projeté

Méthodes de pénalisation

Conditions KKT

Dualité lagrangienne

Methode du gradient projeté

Définition

On suppose que C est **convexe** et **fermé**.

Proposition

Soit $y \in \mathbb{R}^d$. $x \mapsto \|y - x\|^2$ admet un **unique minimiseur** sur C .

Definition

Cet unique minimiseur est appelé **projection orthogonale** de y sur C et est noté $\text{proj}_C(y)$.

Definition (Gradient projeté)

Soit $x^{(1)} \in \mathbb{R}^d$ et $(\gamma^{(t)})_{t \geq 1}$ une suite strictement positive. On appelle **descente de gradient projeté** associée à la fonction objectif f , à l'ensemble convexe fermé C , au point initial $x^{(1)}$ et aux pas $(\gamma^{(t)})_{t \geq 1}$ la suite $(x^{(t)})_{t \geq 1}$ définie par :

$$x^{(t+1)} = \text{proj}_C \left\{ x^{(t)} - \gamma^{(t)} \nabla f(x^{(t)}) \right\}, \quad t \geq 1.$$

Pertinent quand la projection sur C est moins difficile à résoudre que le problème initial.

Garanties pour f convexe

Théorème

On suppose que f admet un minimiseur x^* sur C .

- Si f est convexe et L -régulière, le choix $\gamma^{(t)} = 1/L$ garantit

$$f(x^{(T+1)}) - f(x^*) \leq \frac{L \|x^{(1)} - x^*\|^2}{2T}.$$

- Si f est L -régulière et K -fortement convexe, le choix $\gamma^{(t)} = 1/L$ garantit

$$f(x^{(T+1)}) - f(x^*) \leq \frac{L}{2} \|x^{(1)} - x^*\|^2 \cdot \left(1 - \frac{K}{L}\right)^T.$$

Mêmes garanties que pour la descente de gradient pour la minimisation sans contraintes.

Garanties pour f non-convexe

On définit une application de «gradient alternatif» associée à f et C par :

$$G_\gamma(x) = \frac{x - \text{Proj}_C(x - \gamma \nabla f(x))}{\gamma}, \quad x \in \mathbb{R}^d, \gamma > 0.$$

Ce qui assure $x^{(t+1)} = x^{(t)} - \gamma^{(t)} G_{\gamma^{(t)}}(x^{(t)})$.

Théorème

Si f est seulement L -régulière, le choix $\gamma^{(t)} = 1/L$ garantit

$$\min_{1 \leq t \leq T} \|G_{1/L}(x^{(t)})\|^2 \leq \frac{4L(f(x^{(1)}) - f(x^*))}{T}.$$

Méthodes de pénalisation

Pénalisation extérieure

- On remplace la contrainte par un terme supplémentaire dans la fonction à minimiser.
- On se donne $\phi: \mathbb{R}^d \rightarrow \mathbb{R}$ une fonction telle que :

$$\phi(x) = 0 \text{ si } x \in C, \quad \text{et} \quad \phi(x) > 0 \text{ si } x \notin C.$$

- Soit $\varepsilon > 0$ et on considère le problème approché :

$$\begin{array}{ll} \text{minimiser} & f(x) + \frac{1}{\varepsilon} \phi(x) \\ \text{soumis à} & x \in \mathbb{R}^d. \end{array}$$

- Plus ε est petit, plus le problème est proche du problème initial.
- La solution x_ε^* peut ne pas appartenir à C .

Exemple de résolution par pénalisation

- **Principe** : on résout successivement des approximations de plus en plus proches du problème initial.
- On choisit $\varepsilon^{(1)} > 0$, et on résout approximativement :

$$\begin{aligned} &\text{minimiser} && f(x) + \frac{1}{\varepsilon^{(1)}} \phi(x) \\ &\text{soumis à} && x \in \mathbb{R}^d. \end{aligned}$$

par une méthode de notre choix.

- À l'étape $t \geq 2$,
 - on choisit $\varepsilon^{(t)}$ tel que $0 < \varepsilon^{(t)} < \varepsilon^{(t-1)}$
 - on résout approximativement :

$$\begin{aligned} &\text{minimiser} && f(x) + \frac{1}{\varepsilon^{(t)}} \phi(x) \\ &\text{soumis à} && x \in \mathbb{R}^d. \end{aligned}$$

en prenant $x^{(t-1)}$ pour point initial.

Pénalisation intérieure

Si on souhaite des solutions approchées appartenant strictement à C

- On se donne $\phi: \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ telle que :

$$\forall x \notin C, \quad \phi(x) = +\infty.$$

- Soit $\varepsilon > 0$ et on considère :

$$\begin{array}{ll} \text{minimiser} & f(x) + \varepsilon \phi(x) \\ \text{soumis à} & x \in \mathbb{R}^d \end{array}$$

- Exemple : $C = \mathbb{R}_+^d$. $\phi(x) = -\sum_{i=1}^d \log x_i$.

Conditions KKT

Problèmes de minimisation sous forme standard

$$\begin{array}{ll} \text{minimiser} & f(x) \\ \text{soumis à} & h_i(x) = 0 \quad (1 \leq i \leq p) \\ & g_j(x) \leq 0 \quad (1 \leq j \leq q) \end{array} \quad (\text{P})$$

où les g_j et h_i sont des applications $\mathbb{R}^d \rightarrow \mathbb{R}$.

Autrement dit, il s'agit du problème

$$\min_{x \in C} f(x) \quad \text{où} \quad C = \left\{ x \in \mathbb{R}^d, \quad \begin{array}{l} \forall i = 1, \dots, p, \quad h_i(x) \leq 0 \\ \forall j = 1, \dots, q, \quad g_j(x) = 0 \end{array} \right\}.$$

Definition (Contraintes actives et inactives)

Soit $x \in \mathbb{R}^d$. Une contrainte d'inégalité " $g_j(x) \leq 0$ " est dite **active** (ou **saturée**) (resp. **inactive**) en x si :

$$g_j(x) = 0 \quad (\text{resp.} \quad g_j(x) < 0).$$

Théorème de Fritz John

Théorème (Fritz John)

Soit $x^* \in C$ une solution de (P). Si les fonctions f, g_j, h_i sont \mathcal{C}^1 en x^* , il existe $\lambda_1, \dots, \lambda_p \in \mathbb{R}$ et $(\mu_0, \mu_1, \dots, \mu_q) \in \mathbb{R}_+^q \setminus \{0\}$ tels que :

$$\begin{cases} \mu_0 \nabla f(x^*) + \sum_{i=1}^p \lambda_i \nabla h_i(x^*) + \sum_{j=1}^q \mu_j \nabla g_j(x^*) = 0 \\ \forall j = 1, \dots, q, \quad \mu_j g_j(x^*) = 0. \end{cases}$$

- Si $\mu_0 = 0$, la propriété ci-dessus ne donne aucune information sur f , seulement sur C .
- Les coefficients $(\lambda_i)_{1 \leq i \leq p}$ et $(\mu_j)_{1 \leq j \leq q}$ sont appelés **multiplieurs de Lagrange**

Conditions KKT

Definition

Un point $x^* \in C$ vérifie les conditions KKT (Karush-Kuhn-Tucker) si les f, h_i, g_j sont C^1 en x^* et s'il existe $\lambda_1, \dots, \lambda_p \in \mathbb{R}$ et $\mu_1, \dots, \mu_q \in \mathbb{R}_+$ tels que :

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^p \lambda_i \nabla h_i(x^*) + \sum_{j=1}^q \mu_j \nabla g_j(x^*) = 0 \\ \forall j = 1, \dots, q, \quad \mu_j g_j(x^*) = 0. \end{cases}$$

- On appelle **qualification des contraintes** une condition nécessaire pour qu'une solution de (P) satisfasse les conditions KKT. Il en existe un grand nombre.
- On dit que **les contraintes sont qualifiées** en un point $x \in C$ si une telle condition nécessaire est satisfaite.

Qualification des contraintes

Proposition

Soit $x^* \in C$ une solution de (P). On suppose que les f, g_j, h_i sont \mathcal{C}^1 en x^* . Si de plus *une des conditions* suivantes est vérifiée, alors x^* satisfait les conditions KKT.

- (i) Les fonctions h_i et g_j sont affines
- (ii) la famille composée des vecteurs $\nabla h_i(x^*)$ (pour $i = 1, \dots, p$) et des vecteurs $\nabla g_j(x^*)$ (pour j tel que $g_j(x^*) = 0$) est *linéairement indépendante*.
- (iii) Les fonctions f, g_j sont *convexes*, les h_j *affines*, et il existe $x \in C$ tel que $g_j(x) < 0$ pour tout $j = 1, \dots, q$. (*condition de Slater*)

Il existe de nombreuses autres conditions de qualification.

Réciproque dans le cas convexe

Proposition

*On suppose que les f, g_j, h_i sont \mathcal{C}^1 , que les f, g_j sont **convexes**, et les h_j **affines**. Soit $x^* \in C$ vérifiant les conditions KKT. Alors, x^* est une solution de (P).*

Dualité lagrangienne

Lagrangien

Definition

Le **lagrangien** de (P) est la fonction $L: \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q \rightarrow \mathbb{R}$ définie par :

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^p \lambda_i h_i(x) + \sum_{j=1}^q \mu_j g_j(x).$$

- On voit que :
$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu) = \begin{cases} f(x) & \text{si } x \in C \\ +\infty & \text{sinon.} \end{cases}$$
- Donc (P) se réécrit :
$$\min_{x \in C} f(x) = \min_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu)$$

Dualité faible

On définit le problème dual de (P) par

$$\begin{array}{ll} \text{maximiser} & \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) \\ \text{soumis à} & \lambda \in \mathbb{R}^p \\ & \mu \in \mathbb{R}_+^q. \end{array} \quad (\text{P}^*)$$

Proposition

$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) \leq \inf_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu).$$

Dualité forte

Definition

$(x^*, \lambda^*, \mu^*) \in \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q$ est un **point-selle** du lagrangien si :

$$\forall (x, \lambda, \mu) \in \mathbb{R}^d \times \mathbb{R}^p \times \mathbb{R}_+^q, \quad L(x^*, \lambda, \mu) \leq L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*).$$

Proposition

S'il existe un point-selle (x^, λ^*, μ^*) de L , alors,*

$$\sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} \inf_{x \in \mathbb{R}^d} L(x, \lambda, \mu) = \inf_{x \in \mathbb{R}^d} \sup_{\substack{\lambda \in \mathbb{R}^p \\ \mu \in \mathbb{R}_+^q}} L(x, \lambda, \mu) = L(x^*, \lambda^*, \mu^*).$$

Si de plus, les fonctions f, h_i, g_j sont \mathcal{C}^1 , x^ vérifie les **conditions KKT** avec (λ^*, μ^*) pour multiplicateurs de Lagrange.*

Alors,

- On dit qu'il y a **dualité forte**.
- x^* est solution du problème primal.
- (λ^*, μ^*) est solution du problème dual.

Réciproque dans le cas convexe

Proposition

On suppose que :

- les fonctions f, h_i, g_j sont \mathcal{C}^1
- les fonctions f, g_j sont *convexes*
- les fonctions h_i *affines*.
- $x^* \in C$ une *solution* de (P) vérifiant les *conditions KKT* (on note (λ^*, μ^*) les multiplicateurs de Lagrange).

Alors (x^*, λ^*, μ^*) est un *point-selle* de L .

Et il y a donc dualité forte.

Algorithme d'Uzawa

L'algorithme d'Uzawa, consiste à appliquer la **méthode du gradient projeté au problème dual** (P^*).

- Initialisation : $\lambda^{(1)} \in \mathbb{R}^p, \mu^{(1)} \in \mathbb{R}_+^q$ quelconques.
- Pour $t \geq 1$,

$$x^{(t)} = \arg \min_{x \in \mathbb{R}^d} L(x, \lambda^{(t)}, \mu^{(t)})$$

$$\lambda^{(t+1)} = \lambda^{(t)} + \gamma^{(t)} h_i(x^{(t)}), \quad \forall i = 1, \dots, p,$$

$$\mu^{(t+1)} = \max \left(0, \mu^{(t)} + \gamma^{(t)} g_j(x^{(t)}) \right), \quad \forall j = 1, \dots, q,$$