

TRAVAUX DIRIGÉS D'
OPTIMISATION
MASTER 2 — MATHÉMATIQUES
POUR LES SCIENCES DU VIVANT

Joon Kwon

jeudi 6 octobre 2022



EXERCICE 1 (*Gradient stochastique*). —

1) Soit $t \geq 1$,

$$\|x^{(t+1)} - x^*\| = \|x^{(t)} - \gamma^{(t)} \hat{g}^{(t)} - x^*\|^2 = \|x^{(t)} - x^*\|^2 - 2\gamma^{(t)} \hat{g}^{(t)\top} (x^{(t)} - x^*) + (\gamma^{(t)})^2 \|\hat{g}^{(t)}\|^2.$$

On obtient le résultat en réarrangeant les termes.

2) En sommant l'inégalité de la question 1), on obtient :

$$\sum_{t=1}^T \gamma^{(t)} \hat{g}^{(t)\top} (x^{(t)} - x^*) \leq \frac{1}{2} \|x^{(1)} - x^*\|^2 + \sum_{t=1}^T \frac{(\gamma^{(t)})^2}{2} \|\hat{g}^{(t)}\|^2.$$

On prend l'espérance du membre de droite et on y majore la somme de la façon suivante :

$$\mathbb{E} \left[\sum_{t=1}^T \frac{(\gamma^{(t)})^2}{2} \|\hat{g}^{(t)}\|^2 \right] = \mathbb{E} \left[\sum_{t=1}^T \frac{(\gamma^{(t)})^2}{2} \mathbb{E} [\|\hat{g}^{(t)}\|^2 \mid x^{(t)}] \right] \leq \frac{\sigma^2}{2} \sum_{t=1}^T (\gamma^{(t)})^2.$$

Quant au membre gauche :

$$\begin{aligned} \mathbb{E} \left[\sum_{t=1}^T \gamma^{(t)} \hat{g}^{(t)\top} (x^{(t)} - x^*) \right] &= \mathbb{E} \left[\sum_{t=1}^T \gamma^{(t)} \mathbb{E} [\hat{g}^{(t)\top} (x^{(t)} - x^*) \mid x^{(t)}] \right] \\ &= \mathbb{E} \left[\sum_{t=1}^T \gamma^{(t)} \nabla f(x^{(t)})^\top (x^{(t)} - x^*) \right] \\ &\geq \mathbb{E} \left[\sum_{t=1}^T \gamma^{(t)} (f(x^{(t)}) - f(x^*)) \right]. \end{aligned}$$

où on a utilisé la convexité pour obtenir l'inégalité. On conclut en divisant par $\sum_{t=1}^T \gamma^{(t)}$. Si on choisit $\gamma^{(t)} = \gamma^{(1)} t^{-1/2}$ (pour $t \geq 1$), alors en utilisant les majoration et minoration classiques suivantes :

$$\sum_{t=1}^T \frac{1}{t} = 1 + \int_1^T \frac{1}{u} du = 1 + \log T.$$

$$\sum_{t=1}^T t^{-1/2} \geq \int_1^{T+1} u^{-1/2} du = 2(\sqrt{T+1} - 1) \geq \sqrt{T+1}.$$

Si σ est connu à l'avance, on peut choisir $\gamma^{(1)} = \sigma$ et il en découle la borne

$$\sigma \frac{\|x^{(1)} - x^*\|^2 + 1 + \log T}{2\sqrt{T+1}}.$$

Si σ n'est pas connu à l'avance, le choix $\gamma^{(1)} = 1$ donne la borne

$$\frac{\|x^{(1)} - x^*\|^2 + \sigma^2(1 + \log T)}{2\sqrt{T+1}}.$$

3) En utilisant la caractérisation d'ordre 1 de la régularité, on a pour tout $t \geq 1$,

$$f(x^{(t+1)}) - f(x^{(t)}) \leq \nabla f(x^{(t)})^\top (x^{(t+1)} - x^{(t)}) + \frac{L}{2} \|x^{(t+1)} - x^{(t)}\|^2 \leq -\gamma^{(t)} \nabla f(x^{(t)})^\top \hat{g}^{(t)} + \frac{L(\gamma^{(t)})^2}{2} \|\hat{g}^{(t)}\|^2,$$

où on a utilisé la définition du gradient stochastique pour remplacer $x^{(t+1)} - x^{(t)}$. En sommant, on obtient, en réarrangeant les termes :

$$\sum_{t=1}^T \gamma^{(t)} \nabla f(x^{(t)})^\top \hat{g}^{(t)} \leq f(x^{(1)}) - f(x^{(T+1)}) + \frac{L}{2} \sum_{t=1}^T (\gamma^{(t)})^2 \|\hat{g}^{(t)}\|^2.$$

En prenant l'espérance et en faisant apparaître l'espérance conditionnelle sachant $x^{(t)}$, on obtient :

$$\mathbb{E} \left[\sum_{t=1}^T \gamma^{(t)} \nabla f(x^{(t)})^\top \mathbb{E} [\hat{g}^{(t)} \mid x^{(t)}] \right] \leq f(x^{(1)}) - f(x^{(T+1)}) + \frac{L}{2} \mathbb{E} \left[\sum_{t=1}^T (\gamma^{(t)})^2 \mathbb{E} [\|\hat{g}^{(t)}\|^2 \mid x^{(t)}] \right],$$

ce qui donne :

$$\sum_{t=1}^T \gamma^{(t)} \|\nabla f(x^{(t)})\|^2 \leq f(x^{(1)}) - f(x^*) + \frac{L\sigma^2}{2} \sum_{t=1}^T (\gamma^{(t)})^2.$$

D'où le résultat en divisant par $\sum_{t=1}^T \gamma^{(t)}$. Si on choisit $\gamma^{(t)} = \sqrt{\frac{2}{L\sigma^2 t}}$, de façon similaire à la question précédente, on obtient :

$$\sigma \sqrt{\frac{L}{2}} \frac{f(x^{(1)}) - f(x^*) + 1 + \log T}{\sqrt{T+1}}.$$

4) En utilisant la caractérisation du premier ordre de la forte convexité, on écrit :

$$0 \geq f(x^*) - f(x^{(1)}) \geq \nabla f(x^{(1)})^\top (x^* - x^{(1)}) + \frac{K}{2} \|x^{(1)} - x^*\|^2.$$

Ce qui donne :

$$\frac{K}{2} \|x^{(1)} - x^*\|^2 \leq \nabla f(x^{(1)})^\top (x^* - x^{(1)}).$$

En élevant au carré et en utilisant l'inégalité de Cauchy-Schwarz, on obtient

$$\frac{K^2}{4} \|x^{(1)} - x^*\|^2 \leq \|\nabla f(x^{(1)})\|^2,$$

or le membre de droite peut se majorer par $\mathbb{E} [\|\hat{g}^{(1)}\|^2]$ car :

$$\begin{aligned} \mathbb{E} [\|\hat{g}^{(1)}\|^2] &= \mathbb{E} [\|\nabla f(x^{(1)}) + \hat{g}^{(1)} - \nabla f(x^{(1)})\|^2] \\ &= \|\nabla f(x^{(1)})\|^2 + \mathbb{E} [\|\hat{g}^{(1)} - \nabla f(x^{(1)})\|^2] + 2\nabla f(x^{(1)})^\top \mathbb{E} [\hat{g}^{(1)} - \nabla f(x^{(1)})], \end{aligned}$$

où l'avant dernier terme est positif et le dernier terme est nul.

5) La forte convexité donne entre les points $x^{(t)}$ et x^* les inégalités suivantes.

$$\begin{aligned} f(x^*) - f(x^{(t)}) &\geq \nabla f(x^{(t)})^\top (x^* - x^{(t)}) + \frac{K}{2} \|x^{(t)} - x^*\|^2 \\ f(x^{(t)}) - f(x^*) &\geq \frac{K}{2} \|x^{(t)} - x^*\|^2. \end{aligned}$$

En les utilisant, on écrit alors :

$$\begin{aligned} \mathbb{E} [\|x^{(t+1)} - x^*\|^2] &= \mathbb{E} [\|x^{(t)} - x^*\|^2] + \frac{\sigma^2}{K^2 t^2} - \frac{2}{Kt} \mathbb{E} [\nabla f(x^{(t)})^\top (x^{(t)} - x^*)] \\ &\leq \mathbb{E} [\|x^{(t)} - x^*\|^2] + \frac{\sigma^2}{K^2 t^2} - \frac{2}{Kt} \mathbb{E} \left[f(x^{(t)}) - f(x^*) + \frac{K}{2} \|x^{(t)} - x^*\|^2 \right] \\ &\leq \mathbb{E} [\|x^{(t)} - x^*\|^2] + \frac{\sigma^2}{K^2 t^2} - \frac{2}{Kt} \mathbb{E} [K \|x^{(t)} - x^*\|^2] \\ &\leq \left(1 - \frac{2}{t}\right) \mathbb{E} [\|x^{(t)} - x^*\|^2] + \frac{\sigma^2}{K^2 t^2}. \end{aligned}$$

6) On peut maintenant démontrer que $\mathbb{E} [\|x^{(t)} - x^*\|^2] \leq \frac{4\sigma^2}{K^2 t}$ pour tout $t \geq 1$. Cela a déjà été montré pour $t = 1$. On procède par récurrence. Pour $t \geq 1$, en utilisant l'hypothèse de

récence,

$$\begin{aligned}\mathbb{E} \left[\|x^{(t+1)} - x^*\|^2 \right] &\leq \left(1 - \frac{2}{t} \right) \frac{4\sigma^2}{K^2 t} + \frac{\sigma^2}{K^2 t^2} \\ &= \frac{4\sigma^2}{K^2(t+1)} \frac{4t^2 - 3t - 7}{4t^2} \\ &\leq \frac{4\sigma^2}{K^2(t+1)}.\end{aligned}$$

On conclut en utilisant la caractérisation du premier ordre de la L régularité de f :

$$\mathbb{E} [f(x^{(t)})] - f(x^*) \leq \mathbb{E} \left[\frac{L}{2} \|x^{(t)} - x^*\|^2 \right] \leq \frac{2L\sigma^2}{K^2 t}.$$

